


GPU 进阶笔记（一）：高性能 GPU 服务器硬件拓扑与集群组网（2023）

[About](#)[Donate](#)[RSS](#)

Published at 2023-09-16 | Last Update 2024-05-27

记录一些平时接触到的 GPU 知识。由于是笔记而非教程，因此内容不求连贯，有基础的同学可作查漏补缺之用。



- GPU 进阶笔记（一）：高性能 GPU 服务器硬件拓扑与集群组网（2023）
- GPU 进阶笔记（二）：华为昇腾 910B GPU 相关（2023）
- GPU 进阶笔记（三）：华为 NPU (GPU) 演进（2024）
- GPU 进阶笔记（四）：NVIDIA GH200 芯片、服务器及集群组网（2024）

水平及维护精力所限，文中不免存在错误或过时之处，请酌情参考。传播知识，尊重劳动，年满十八周岁，转载请注明出处。


- 1 术语与基础
 - 1.1 PCIe 交换芯片
 - 1.2 NVLink

- 定义
- 演进：1/2/3/4 代
- 监控
- 1.3 NVSwitch
- 1.4 NVLink Switch
- 1.5 HBM (High Bandwidth Memory)
 - 由来
 - 演进：HBM 1/2/2e/3/3e
- 1.6 带宽单位
- 2 典型 8*A100/8*A800 主机
 - 2.1 主机内拓扑： 2-2-4-6-8-8
 - 存储网卡
 - NVSwitch fabric： intra-node full-mesh
 - 用 `nvidia-smi topo` 查看拓扑
 - 1.2 GPU 训练集群组网： IDC GPU fabirc
 - 计算网络
 - 存储网络
 - RoCE vs. InfiniBand
 - 1.3 数据链路带宽瓶颈分析
- 3 典型 8*H100/8*H800 主机
 - 3.1 H100 芯片 layout
 - 3.2 主机内硬件拓扑
 - 3.3 组网
- 4 典型 4*L40S/8*L40S 主机
 - 4.1 L40S vs A100 配置及特点对比
 - 4.2 L40S 与 A100 性能对比
 - 4.3 L40S 攒机
 - 推荐架构： 2-2-4
 - 不推荐架构： 2-2-8
 - 4.4 组网
 - 4.5 数据链路带宽瓶颈分析
 - 4.6 测试注意事项
- 5 典型 8*H20 GPU 服务器（2024 更新）
 - 5.1 显存： **8*96GB**

- 5.2 卡间互联：NVLINK x18 lanes = 900GB/s
- 5.3 网络
- 5.4 训练性能：8*A100 vs 8*A800
- 参考资料

1 术语与基础

大模型训练一般都是用单机 8 卡 GPU 主机组成集群，机型包括 $8 \times \{A100, A800, H100, H800\}$ 可能还会用最近即将上市的 $\{4, 8\} \times L40S$ 等。下面一台典型 8*A100 GPU 的主机内硬件拓扑：



典型 8 卡 A100 主机硬件拓扑

本节将基于这张图来介绍一些概念和术语，有基础的可直接跳过。

1.1 PCIe 交换芯片

CPU、内存、存储（NVME）、GPU、网卡等**支持 PCIe 的设备**，都可以连接到 PCIe 总线或专门的 PCIe 交换芯片，实现互联互通。

PCIe 目前有 5 代产品，最新的是 **Gen5**。

1.2 NVLink

定义

Wikipedia 上 **NVLink** 上的定义：


NVLink is a wire-based serial multi-lane near-range communications link developed by Nvidia. Unlike PCI Express, a device can consist of multiple NVLinks, and devices use mesh networking to communicate instead of a central hub. The protocol was first announced in March 2014 and uses a proprietary high-speed signaling interconnect (NVHS).

简单总结：同主机内不同 GPU 之间的一种高速互联方式，

1. 是一种短距离**通信链路**，保证包的成功传输，更高性能，替代 PCIe，
2. 支持多 lane，link 带宽随 lane 数量线性增长，
3. 同一台 node 内的 GPU 通过 NVLink 以 **full-mesh** 方式（类似 spine-leaf）互联，
4. NVIDIA 专利技术。

演进：1/2/3/4 代

主要区别是单条 NVLink 链路的 **lane 数量**、每个 **lane 的带宽**（图中给的都是双向带宽）等：




NVLink 演进。Image from: HotChips 2022 [1]

例如，

- A100 是 $2 \text{ lanes/NVSwitch} * 6 \text{ NVSwitch} * 50\text{GB/s/lane} = 600\text{GB/s}$ 双向带宽（单向 300GB/s）。注意：这是一个 GPU 到所有 NVSwitch 的总带宽；
- A800 被阉割了 4 条 lane，所以是 $8 \text{ lane} * 50\text{GB/s/lane} = 400\text{GB/s}$ 双向带宽（单向 200GB/s）。

监控


基于 DCGM 可以采集到实时 NVLink 带宽：



Metrics from dcgm-exporter [5]

1.3 NVSwitch

还是参考下图，



典型 8 卡 A100 主机硬件拓扑

NVSwitch 是 NVIDIA 的一款**交换芯片**，封装在 GPU module 上，并不是主机外的独立交换机。

下面是真机图，浪潮的机器，图中 8 个盒子就是 8 片 A100，右边的 6 块超厚散热片下面就是 NVSwitch 芯片：



Inspur NF5488A5 NVIDIA HGX A100 8 GPU Assembly Side View. Image source: [2]

1.4 NVLink Switch

NVSwitch 听名字像是交换机，但实际上是 GPU module 上的交换芯片，用来连接同一台主机内的 GPU。

2022 年，NVIDIA 把这块芯片拿出来真的做成了交换机，叫 **NVLink Switch** [3]，用来跨主机连接 GPU 设备。

这两名字很容易让人混淆。

1.5 HBM (High Bandwidth Memory)

由来

传统上，GPU 显存和普通内存（DDR）一样插在主板上，通过 PCIe 连接到处理器（CPU、GPU），因此速度瓶颈在 PCIe，Gen4 是 64GB/s，Gen5 是 128GB/s。

因此，一些 GPU 厂商（不是只有 NVIDIA 一家这么做）将多个 **DDR 芯片堆叠之后与 GPU 芯片封装到一起**（后文讲到 H100 时有图），这样每片 GPU 和它自己的显存交互时，就不用再去 PCIe

交换芯片绕一圈，速度最高可以提升一个量级。这种“高带宽内存”（High Bandwidth Memory）缩写就是 HBM。


现在 CPU 也有用 HBM 的了，比如 Intel Xeon CPU Max Series 就自带了 64GB HBM2e。

HBM 的市场目前被 SK 海力士和三星等韩国公司垄断。

演进：HBM 1/2/2e/3/3e

From wikipedia HBM,

	Bandwidth	Year	GPU
HBM	128GB/s/package		
HBM2	256GB/s/package	2016	V100
HBM2e	~450GB/s	2018	A100, ~2TB/s ; 华为 Ascend 910B
HBM3	600GB/s/site	2020	H100, 3.35TB/s
HBM3e	~1TB/s	2023	H200 , 4.8TB/s



使用了 HBM 的近几代高端 NVIDIA GPU 显存带宽（双向），纵坐标是 TB/s。Image source: [3]

- AMD MI300X 采用 192GB HBM3 方案，带宽 **5.2TB/s**；
- HBM3e 是 HBM3 的增强版，速度从 6.4GT/s 到 8GT/s。

1.6 带宽单位

大规模 GPU 训练的性能与数据传输速度有直接关系。这里面涉及到很多链路，比如 PCIe 带宽、内存带宽、NVLink 带宽、HBM 带宽、网络带宽等等。


- 网络习惯用 **bits/second (b/s)** 表示之外，并且一般说的都是**单向**（TX/RX）；
- 其他模块带宽基本用 **byte/second (B/s)** 或 **transactions/second (T/s)** 表示，并且一般都是**双向总带宽**。

比较带宽时注意区分和转换。

2 典型 8*A100/8*A800 主机


2.1 主机内拓扑： 2-2-4-6-8-8

- 2 片 CPU（及两边的内存，NUMA）
- 2 张**存储网卡**（访问分布式存储，带内管理等）
- 4 个 PCIe Gen4 Switch 芯片
- 6 个 NVSwitch 芯片
- 8 个 GPU
- 8 个 **GPU 专属网卡**



典型 8 卡 A100 主机硬件拓扑

下面这个图画的更专业，需要更多细节的可参考：



NVIDIA DGX A100 主机（官方 8 卡机器）硬件拓扑。Image source: [4]

存储网卡

通过 PCIe 直连 CPU。用途：

1. 从分布式存储读写数据，例如读训练数据、写 checkpoint 等；
2. 正常的 node 管理，ssh，监控采集等等。

官方推荐用 BF3 DPU。但其实只要带宽达标，用什么都行。组网经济点的话用 RoCE，追求最好的性能用 IB。


NVSwitch fabric: intra-node full-mesh

8 个 GPU 通过 6 个 NVSwitch 芯片 full-mesh 连接，这个 full-mesh 也叫 **NVSwitch fabric**；full-mesh 里面的每根线的带宽是 $n * bw-per-nvlink-lane$,

- A100 用的 NVLink3，**50GB/s/lane**，所以 full-mesh 里的每条线就是 **$12 * 50GB/s = 600GB/s$** ，注意这个是双向带宽，单向只有 300GB/s。
- A800 是阉割版，**12 lane 变成 8 lane**，所以每条线 $8 * 50GB/s = 400GB/s$ ，单向 200GB/s。

用 nvidia-smi topo 查看拓扑

下面是一台 8*A800 机器上 **nvidia-smi** 显示的实际拓扑（网卡两两做了 bond，NIC 0~3 都是 bond）：




- GPU 之间（左上角区域）：都是 **NV8**，表示 **8 条 NVLink** 连接；
- NIC 之间：

- 在同一片 CPU 上： **NODE** ，表示不需要跨 NUMA，但需要跨 PCIe 交换芯片；
- 不在同一片 CPU 上： **SYS** ，表示需要跨 NUMA；
- GPU 和 NIC 之间：
 - 在同一片 CPU 上，且在同一个 PCIe Switch 芯片下面： **PXB** ，表示只需要跨 PCIe 交换芯片；
 - 在同一片 CPU 上，且不在同一个 PCIe Switch 芯片下面： **NODE** ，表示需要跨 PCIe 交换芯片和 PCIe Host Bridge；
 - 不在同一片 CPU 上： **SYS** ，表示需要跨 NUMA、PCIe 交换芯片，距离最远；

1.2 GPU 训练集群组网：IDC GPU fabric

GPU node 互联架构：



计算网络

GPU 网卡直连到置顶交换机（leaf），leaf 通过 full-mesh 连接到 spine，形成跨主机 GPU 计算网络。

- 这个网络的目的是 GPU 与其他 node 的 GPU 交换数据；
- 每个 GPU 和自己的网卡之间通过 **PCIe 交换芯片** 连接： GPU <--> PCIe Switch <--> NIC 。

存储网络


直连 CPU 的两张网卡，连接到另一张网络里，主要作用是读写数据，以及 SSH 管理等等。

RoCE vs. InfiniBand

不管是计算网络还是存储网络，都需要 RDMA 才能实现 AI 所需的高性能。RDMA 目前有两种选择：

- RoCEv2：公有云卖的 8 卡 GPU 主机基本都是这种网络，比如 CX6 **8*100Gbps** 配置；在性能达标的前提下，（相对）便宜；
- InfiniBand (IB)：同等网卡带宽下，性能比 RoCEv2 好 20% 以上，但是价格贵一倍。

1.3 数据链路带宽瓶颈分析



单机 8 卡 A100 GPU 主机带宽瓶颈分析

几个关键链路带宽都标在图上了，

1. 同主机 GPU 之间：走 NVLink，双向 600GB/s，单向 **300GB/s**；
2. 同主机 GPU 和自己的网卡之间：走 PCIe Gen4 Switch 芯片，双向 64GB/s，单向 **32GB/s**；
3. 跨主机 GPU 之间：需要通过网卡收发数据，这个就看网卡带宽了，目前国内 A100/A800 机型配套的主流带宽是（单向）**100Gbps=12.5GB/s**。所以跨机通信相比主机内通信性能要下降很多。
 - 200Gbps==25GB/s：已经**接近** PCIe Gen4 的单向带宽；
 - 400Gbps==50GB/s：已经**超过** PCIe Gen4 的单向带宽。

所以在这种机型里用 400Gbps 网卡作用不大，400Gbps 需要 PCIe Gen5 性能才能发挥出来。


3 典型 8*H100/8*H800 主机

GPU Board Form Factor 分为两种类型：

- PCIe Gen5
- SXM5：性能更高一些

3.1 H100 芯片 layout

下面是一片 H100 GPU 芯片的内部结构：




单片 H100 GPU 内部逻辑布局。Image source: [3]

- 4nm 工艺；
- 最下面一排是 18 根 Gen4 NVLink；双向总带宽 $18 \text{ lanes} * 50\text{GB/s/lane} = 900\text{GB/s}$ ；
- 中间蓝色的是 L2 cache；
- 左右两侧是 HBM 芯片，即显存；

3.2 主机内硬件拓扑

跟 A100 8 卡机结构大致类似，区别：

1. NVSwitch 芯片从 6 个减少到了 4 个；真机图如下，



2. 与 CPU 的互联从 PCIe Gen4 x16 升级到 **PCIe Gen5 x16**，双向带宽 **128GB/s**；




Image source: exxactcorp.com

3.3 组网

与 A100 也类似，只是标配改成了 **400Gbps** 的 CX7 网卡，否则网络带宽与 PCIe Switch 和 NVLink/NVSwitch 之间的差距更大了。

4 典型 4*L40S/8*L40S 主机

L40S 是今年（2023）即将上市的新一代“性价比款”多功能 GPU，**对标 A100**。除了不适合训练基座大模型之外（后面会看到为什么），官方的宣传里它几乎什么都能干。价格的话，目前第三方服务器厂商给到的口头报价都是 A100 的 8 折左右。

4.1 L40S vs A100 配置及特点对比

L40S 最大的特点之一是 **time-to-market 时间短**，也就是从订货到拿到货周期比 A100/A800/H800 快很多。这里面技术和非技术原因都有，比如：

- 不存在被美国禁售的功能（根据 2023.10 的新规定，已经禁售了），比如 **FP64** 和 **NVLink** 都干掉了；
- 使用 **GDDR6** 显存，不依赖 HBM 产能（及先进封装）；

价格便宜也有几方面原因，后面会详细介绍：

1. 大头可能来自 GPU 本身价格降低：因为去掉了一些模块和功能，或者用便宜的产品替代；
2. 整机成本也有节省：例如去掉了一层 PCIe Gen4 Switch；不过相比于 4x/8x GPU，整机的其他部分都可以说送的了；

4.2 L40S 与 A100 性能对比

下面是一个官方标称性能对比：

NVIDIA L40S Specifications

	L40S	A100 80GB SXM
Best For	Universal GPU for Gen AI	Highest Perf Multi-Node AI
GPU Architecture	NVIDIA Ada Lovelace	NVIDIA Ampere
FP64	N/A	9.7 TFLOPS
FP32	91.6 TFLOPS	19.5 TFLOPS
RT Core	212 TFLOPS	N/A
TF32 Tensor Core*	366 TFLOPS	312 TFLOPS
FP16/BF16 Tensor Core*	733 TFLOPS	624 TFLOPS
FP8 Tensor Core*	1466 TFLOPS	N/A
INT8 Tensor Core*	1466 TOPS	1248 TOPS
GPU Memory	48 GB GDDR6	80 GB HBM2e
GPU Memory Bandwidth	864 GB/s	2039 GB/s
L2 Cache	96 MB	40 MB
Media Engines	3 NVENC (+AV1) 3 NVDEC 4 NVJPEG	0 NVENC 5 NVDEC 5 NVJPEG
Power	Up to 350 W	Up to 400 W
Form Factor	2-slot FHFL	8-way HGX
Interconnect	PCIe Gen4 x16: 64 GB/s	PCIe Gen4 x16: 64 GB/s
Availability	August 2023	Longer Leadtime

Preliminary specifications for L40S, subject to change.
* Specifications with sparsity.

具体场景的性能对比网上也有很多官方资料，这里就不列举了。简单来，


- 性能 1.2x ~ 2x（看具体场景）。
- 功耗：两台 L40S 和单台 A100 差不多

需要注意，**L40S 主机官方推荐的是单机 4 卡而不是 8 卡**（后面会介绍为什么），所以对比一般是用 两台 4*L40S vs 单台 8*A100 。另外，很多场景的性能提升有个 **大前提**：网络需要是 200Gbps RoCE 或 IB 网络，接下来介绍为什么。

4.3 L40S 攒机

推荐架构： 2-2-4

相比于 A100 的 **2-2-4-6-8-8** 架构，官方推荐的 L40S GPU 主机是 2-2-4 架构，一台机器物理拓扑如下：




推荐单机 4 卡 L40S GPU 主机拓扑

最明显的变化是去掉了 CPU 和 GPU 之间的 PCIe Switch 芯片，网卡和 GPU 都是直连 CPU 上自带的 PCIe Gen4 x16 (64GB/s)，

- 2 片 CPU (NUMA)
- 2 张双口 CX7 网卡（每张网卡 **2*200Gbps**）
- 4 片 L40S GPU
- 另外，存储网卡只配 1 张（双口），直连在任意一片 CPU 上

这样每片 GPU 平均 200Gbps 网络带宽。

不推荐架构：2-2-8



单机 8 卡 L40S GPU 主机拓扑，来自 NVIDIA L40S 官方推介材料


如图，跟单机 4 卡相比，单机 8 卡需要引入两片 PCIe Gen5 Switch 芯片：

- 说是现在 **PCIe Gen5 Switch** 单片价格 1w 刀（不知真假），一台机器需要 2 片；价格不划算；
- PCIe switch 只有一家在生产，产能受限，周期很长；
- 平摊到每片 GPU 的网络带宽减半；

4.4 组网

官方建议 4 卡机型，搭配 200Gbps RoCE/IB 组网。

4.5 数据链路带宽瓶颈分析



单机 4 卡 L40S GPU 主机带宽瓶颈分析

以同 CPU 下面的两种 L40S 为例，这里面有两条链路可选：

1. 直接通过 CPU 处理： GPU0 <---PCIe---> CPU <---PCIe---> GPU1

- PCIe Gen4 x16 双向 64GB/s，单向 **32GB/s** ；
- **CPU 处理瓶颈？ TODO**

2. 完全绕过 CPU 处理，通过网卡去外面绕一圈再回来： GPU0 <---PCIe---> NIC <--- RoCe/IB Switch ---> NIC <---PCIe---> GPU1

- PCIe Gen4 x16 双向 64GB/s，单向 **32GB/s** ；
- 平均每个 GPU 一个单向 200Gbps 网口，单向折算 **25GB/s** ；
- **需要 NCCL 支持**，官方说新版本 NCCL 正在针对 L40S 适配，默认行为就是去外面绕一圈回来；

- 任何两片 GPU 的通信带宽和延迟都是一样的，是否在一台机器内或一片 CPU 下面并不重要，集群可以**横向扩展**（scaling up, compared with scaling in）；
- GPU 机器成本降低；但其实对于那些对网络带宽要求没那么高的业务来说，是把 **NVLINK** 的成本转嫁给了网络，这时候必须要组建 200Gbps 网络，否则发挥不出 L40S 多卡训练的性能。

- L40S: 200Gbps (网卡单向线速)
- A100: 300GB/s (NVLINK3 单向) == **12x** 200Gbps
- A800: 200GB/s (NVLINK3 单向) == **8x** 200Gbps

4.6 测试注意事项

5 典型 8*H20 GPU 服务器 (2024 更新)

5.1 显存： 8*96GB

```

$ nvidia-smi
+-----+
| NVIDIA-SMI 535.161.03                Driver Version: 535.161.03      CUDA Version: 12.1.0 |
+-----+-----+-----+-----+-----+-----+
| GPU  Name                               Persistence-M | Bus-Id        Disp.A | Volatile Uncorr |
| Fan  Temp      Perf          Pwr:Usage/Cap |      Memory-Usage | GPU-Util  Comput |
|                               |                    |            M.    |
+=====+=====+=====+=====+=====+=====+
|    0  NVIDIA H20                        On      | 00000000:04:00.0 Off |             De |
| N/A    24C    P0              72W / 500W |      0MiB / 97871MiB |      0%    Dis |
+-----+-----+-----+-----+-----+-----+

```

+-----+-----+-----+										
	1	NVIDIA	H20		On		00000000:23:00.0	Off		
	N/A	24C	P0		71W / 500W		0MiB / 97871MiB			0% De
										Dis
+-----+-----+-----+										
...										
	7	NVIDIA	H20		On		00000000:E4:00.0	Off		
	N/A	24C	P0		72W / 500W		0MiB / 97871MiB			0% De
										Dis

GPU 最大功耗 8*500W 。

5.2 卡间互联：NVLINK x18 lanes = 900GB/s

```
$ nvidia-smi topo -m
```

	GPU0	GPU1	GPU2	GPU3	GPU4	GPU5	GPU6	GPU7	NIC0	NIC1
GPU0	X	NV18	NV18	NV18	NV18	NV18	NV18	NV18	SYS	SYS
GPU1	NV18	X	NV18	NV18	NV18	NV18	NV18	NV18	SYS	SYS
GPU2	NV18	NV18	X	NV18	NV18	NV18	NV18	NV18	SYS	SYS
GPU3	NV18	NV18	NV18	X	NV18	NV18	NV18	NV18	SYS	SYS
GPU4	NV18	NV18	NV18	NV18	X	NV18	NV18	NV18	NODE	NODE
GPU5	NV18	NV18	NV18	NV18	NV18	X	NV18	NV18	NODE	NODE
GPU6	NV18	NV18	NV18	NV18	NV18	NV18	X	NV18	PHB	PHB
GPU7	NV18	NV18	NV18	NV18	NV18	NV18	NV18	X	NODE	NODE
NIC0	SYS	SYS	SYS	SYS	NODE	NODE	PHB	NODE	X	PIX
NIC1	SYS	SYS	SYS	SYS	NODE	NODE	PHB	NODE	PIX	X

可以看到双向 **18 lanes * 50GB/s/lane= 900GB/s** （单向 450GB/s）。作为对比，8*A800 NVLINK 是 8 lanes，见前面章节。

5.3 网络

这个看各服务器厂商怎么配了。下面是国内某家的 PCIe 和网卡信息：

```
$ lspci
```

00:00.0	Host bridge: Advanced Micro Devices, Inc. [AMD] Device 14a4 (rev 01)	
c0:00.2	IOMMU: Advanced Micro Devices, Inc. [AMD] Device 149e (rev 01)	
c0:01.1	PCI bridge: Advanced Micro Devices, Inc. [AMD] Device 14ab (rev 01)	
c1:00.0	PCI bridge: Broadcom / LSI PEX890xx PCIe Gen 5 Switch (rev b0)	#
c2:00.0	PCI bridge: Broadcom / LSI PEX890xx PCIe Gen 5 Switch (rev b0)	
c3:00.0	3D controller: NVIDIA Corporation Device 2329 (rev a1)	
c6:00.0	Ethernet controller: Mellanox Technologies MT2894 Family [ConnectX-6 Lx]	#

RDMA:

```
$ ibstat
CA 'mlx5_0'
  CA type: MT4127
  Number of ports: 1
  Port 1:
    State: Down
    Physical state: Disabled
    Rate: 40
    Base lid: 0
    LMC: 0
    SM lid: 0
    Capability mask: 0x00010000
    Link layer: Ethernet
CA 'mlx5_1'
  CA type: MT4127
  Number of ports: 1
  Port 1:
    State: Down
    Physical state: Disabled
    Rate: 40
    Base lid: 0
    LMC: 0
    SM lid: 0
    Capability mask: 0x00010000
    Link layer: Ethernet
```

5.4 训练性能： 8*H20 vs 8*A800


单机 8 卡训练性能（实测数据，但大家用的模型、框架、数据集等可能各不相同，因此这里的结果仅供参考）：

GPU Node (NVLINK interconnect)	Throughput
8*A800-80GB	~30 samples/sec
8*H20-96GB	~21 samples/sec


相比 A800，H20 纸面算力阉割了一半左右 [6]，但在 NVLINK/cache 等地方补了一下，所以实际性能（只）下降了 1/3。

参考资料

1. NVLink-Network Switch - NVIDIA's Switch Chip for High Communication-Bandwidth SuperPODs, Hot Chips 2022
2. ChatGPT Hardware a Look at 8x NVIDIA A100 Powering the Tool, 2023
3. NVIDIA Hopper Architecture In-Depth, nvidia.com, 2022
4. DGX A100 review: Throughput and Hardware Summary, 2020
5. Understanding NVIDIA GPU Performance: Utilization vs. Saturation, 2023
6. GPU Performance (Data Sheets) Quick Reference (2023)



written by human
not by AI



written by human
not by AI

« [译] 如何训练一个企业级 GPT 助手 (OPENAI, 2023)

LINUX LOAD AVERAGE: 算法、实现与实用指南 (2023) »

© 2016-2026 [Arthur Chiao](#), Powered by [Jekyll](#), customized [Long Haul](#). Site visits: 3051218, powered by [busuanzi](#)

